

1. Teorik Uygulama Çözümleri

Teorik Uygulama 1

Verilen 16 adet değer, 4 satırlık (3 öznitelik X1, X2, X3 ve 1 hedef değişken Y) bir veri seti olduğunu varsayıyoruz:

X1	X2	X3	Y
0	1	0	-1
1	0	0	1
0	1	1	1
0	0	1	-1

Soru 1: Karar ağacımızın kök düğümünde hangi öznitelige göre bölme yaparız ve Gini safsızlık ölçüsü kullanıldığında bu öznitelikten elde edeceğimiz bilgi kazancı (Information Gain) ne olur?

2. Teorik Uygulama 1: Detaylı Açıklama

Bu senaryoda elimizde 4 hastanın 3 özelliği (X1, X2, X3) ve hastalık durumu (Y) vardır. Durumlar: İki kişi hasta (1), iki kişi sağlıklı (-1).

Kök Düğümün Seçimi ve Bilgi Kazancı

Başlangıçta odada 2 hasta, 2 sağlıklı kişi vardır. Durum maksimum derecede karışıktır.

- Başlangıç Gini Safsızlığı: $1 - (0.5^2 + 0.5^2) = 0.5$

Karar ağacı sırayla tüm özellikleri dener:

1. Eğer X1 özelliğine göre bölersek: X1=1 olan sadece 1 kişi vardır ve o kişi hastadır. Bu dal tamamen "saftır" (Gini = 0). Geriye kalan 3 kişi diğer dala gider. Bu işlemin sonucunda toplam karışıklık 0.5'ten 0.333'e düşer.

2. Bilgi Kazancı (X1): $0.5 - 0.333 = 0.167$

Diğer özelliklere (X2 ve X3) göre böldüğümüzde karışıklık (0.5) hiç azalmaz, bilgi kazancı 0 çıkar. Bu sebeple algoritma en yüksek kazancı sağlayan X1 özelliğini ağacın en tepesine (Kök Düğüm) yerleştirir.

Ağaç Derinliği ve Yeni Veri Sınıflandırması

- Herkesi birbirinden ayırıp "saf" yapraklar elde etmek için sırasıyla X1, X2 ve X3'ü sormak zorundayız. Toplamda 3 soru sorulduğu için ağacın maksimum derinliği (depth) 3 olur.

- Bize (0, 0, 0) özelliklerine sahip yeni bir hasta gelirse; ağaç önce X1=0 dalından, sonra X2=0 dalından ilerler. Bu yoldaki veri "-1" olduğu için algoritma yeni hastaya -1 (sağlıklı) teşhisini koyar.

Soru 2: Ağacın derinliği kaçtır?

- Veri seti X1, ardından X2 ve en son X3 kullanılarak tam olarak saflaştırılabilir. Tüm öznitelikler dallanma için kullanıldığında maksimum derinlik 3 olur.

Soru 3: (0, 0, 0) özelliklerine sahip bir veri noktası nasıl sınıflandırılır?

- Ağaç yapısına göre; X1=0 dalından gidilir. Sonra X2=0 dalından gidilir. Veri setimizde X1=0, X2=0 olan tek örnek son satırdır ve etiketi -1'dir. Bu nedenle veri noktası -1 olarak sınıflandırılır.

Teorik Uygulama 2

Verilen 12 adet değer, 3 satırlık veri seti olduğu varsayımıyla:

X1	X2	X3	Y
0	0	1	0
1	1	1	0
1	1	1	-1

Soru 1: Gini ve Entropi kullanıldığında ilk bölünmeden sonraki bilgi kazancı ne olacaktır?

Kök Düğüm Safsızlık Kıyaslaması

Başlangıçtaki karışıklığı her iki formülle hesapladığımızda ölçek farkını net olarak görebiliriz:

- Gini ile başlangıç safsızlığı: $1 - ((2/3)^2 + (1/3)^2) = 0.444$

- Entropi ile başlangıç safsızlığı: $-(2/3 * \log_2(2/3) + 1/3 * \log_2(1/3)) = 0.918$

İlk Bölünmeden Sonraki Bilgi Kazançları

Ağaç veriyi en iyi ayıran özelliğe göre böldüğünde (safsızlık azaldığında):

- Gini kullanıldığında Bilgi Kazancı: Başlangıç (0.444) - Bölünme Sonrası (0.333) = 0.111

- Entropi kullanıldığında Bilgi Kazancı: Başlangıç (0.918) - Bölünme Sonrası (0.667) = 0.251

Önemli: Entropi'nin bilgi kazancı sayısal olarak daha yüksek ($0.251 > 0.111$) görünse de, bu durum Entropi'nin 1.0 üzerinden, Gini'nin ise 0.5 üzerinden ölçeklenmesinden kaynaklanır. Karar mekanizması (oranlar) tamamen aynıdır.

Nihai Ağaç Derinliği

Veri setinin son iki satırına bakıldığında, hastaların özellikleri tamamen aynı olmasına (1, 1, 1) rağmen sonuçları (0 ve -1) farklıdır. Makine öğrenmesinde buna "çakışan (contradictory) veri" denir. Ağaç bu iki hastayı birbirinden ayırt edecek başka bir özellik

bulamadığı için dallanmayı durdurur. Sadece tek bir bölünme yapılabildiği için nihai derinlik 1 olarak kalır.

Soru 2: Oluşan nihai ağacın derinliği kaçtır?

- Veri setinde son iki satırın öznitelikleri aynı fakat hedefleri farklıdır (0 ve -1). Bu sebeple veri seti daha fazla saflaştırılamaz. Tek bir bölünme gerçekleşir. Derinlik 1'dir.

2. Pratik Uygulama 1 Raporu

Görev: Deneme.py içindeki az kayıtlı veri setinin analizi ile çoğaltılmış veri setinin kıyaslanması.

- Orijinal (10 Kayıtlı) Analiz Sonucu: Test seti çok küçük (3 adet) olduğu için Decision Tree bu veriyi kolayca ezberlemiş ve doğruluk oranı %100 çıkmıştır.

- Çoğaltılmış (200 Kayıtlı) Analiz Sonucu: Rastgele oluşturulan ve eksik değerler serpiştirilen 200 adet veri setiyle yapılan analizde doğruluk oranı %75 çıkmıştır.

- Kıyaslama ve Yorum: Az kayıtlı veri setlerinde test seti çok küçük olduğu için modelin performansı yapay bir şekilde yüksek çıkmıştır. Gerçek hayatta 10 veri ile kurulan bir ağaç, yeni verileri genellemekte başarısız olur. 200 satırlık veri ile kurulan model daha iyi genellenebilir bir yapı sunar.

3. Pratik Uygulama 2 Raporu

Görev: Heart attack.csv ile inme tahmini, One-Hot Encoding ve modelin Overfitting açısından incelenmesi.

- Eksik veriler doldurulmuş, kategorik değişkenler One-Hot Encoding ile dönüştürülmüştür.

- Veri %70 Eğitim, %30 Test olarak ayrılmıştır.

Aşırı Öğrenme (Overfitting) Analizi:

- Kısıtlamasız Karar Ağacı: Eğitim Doğruluğu: %100, Test Doğruluğu: %87.9

Yorum: Derinliğe sınır konulmadığında ağaç eğitim verisini ezberlemiş, test verisinde başarısı düşmüştür. Bu durum aşırı öğrenmedir.

- Budanmış Karar Ağacı (max_depth=4): Eğitim Doğruluğu: %80.97, Test Doğruluğu: %80.22

Yorum: Maksimum derinlik 4 ile sınırlandırıldığında eğitim ve test performansları birbirine çok yaklaşmıştır. Model ezberlemek yerine genel kuralları öğrenmiştir.

Ağaç Yapısı ve Tıbbi Yorum:

- Kök Düğümdeki Öznitelik: age (Yaş)

- Tıbbi Gerekçe: Karar ağacı algoritması kök düğüme, Gini safsızlığını en çok azaltan değişkeni koyar. Yaş faktörü inme riskini ayırmada en temel ayırt edici öznelik olarak tespit edilmiştir ki bu durum tıp literatürüyle birebir uyuşmaktadır.

